

CONCORDE

Trust layer for voice channels in banking

DOCUMENTO	Especificación Técnica y Acta de Proyecto <i>Technical Specification & Project Charter</i>
VERSIÓN	1.0 — línea base congelada (baseline)
FECHA	11 de septiembre de 2026, 21:00 CST
RETO	Defend the Bank Against Voice Deepfakes — Tecnologías Altur S.A.P.I. de C.V.
EQUIPO	Paul (Arquitectura / Backend Rust · Doc owner) · Néstor (Frontend / UX) · Diego (ML / Datos)
VENTANA	11 sep 20:00 → 13 sep 09:00 (≈37 h) · Judging 13 sep 09:00–13:00
ESTADO	Aprobado para ejecución · Sujeto a resolución de supuestos §16

Aviso de manejo de datos. Este documento hace referencia al dataset `altur-challenge`, provisto bajo términos de uso exclusivo para HackMTY 2026 y sin derecho de redistribución. El dataset **no** se versiona en el repositorio del equipo, no se publica en artefactos de despliegue y no se intentará identificar a ningún hablante. Ver §13.4.

Data handling notice. This document references the `altur-challenge` dataset, provided for HackMTY 2026 use only and not for redistribution. The dataset is not committed to the team repository, not shipped in deployment artifacts, and no attempt will be made to identify any speaker. See §13.4.

0 Control del documento / Document control

0.1 Convención de idioma / Language convention

Este documento es bilingüe bajo una regla deliberada, no arbitraria: las secciones **narrativas y de gestión** (resumen, decisiones, cronograma, riesgos, DoD) se presentan en español seguidas de un bloque equivalente en inglés. Los **artefactos normativos** (identificadores de requerimientos, contrato de API, catálogo de features, tabla de tareas, esquemas JSON) se mantienen **únicamente en inglés**, porque se copian literalmente al código, al `README.md` del entregable y a la conversación con los jueces de Altur. Duplicarlos introduciría dos fuentes de verdad y, con ello, ambigüedad — exactamente lo que este documento existe para eliminar.

EN

This document is bilingual under a deliberate rule. Narrative and management sections appear in Spanish followed by an English equivalent. Normative artifacts — requirement IDs, the API contract, the feature catalog, the task table and JSON schemas — are kept in English only, because they are copied verbatim into the code, the deliverable `README.md`, and conversations with Altur's judges. Duplicating them would create two sources of truth and therefore ambiguity, which is precisely what this document exists to remove.

0.2 Estado de aprobación / Approval

ROL	PERSONA	RESPONSABILIDAD (RACI)	ESTADO
Arquitecto / PM	Paul	Accountable por arquitectura, contrato de API, servicio Rust, despliegue	Aprobado
Frontend Lead	Néstor	Responsible por dashboard, sistema de diseño, integración WS/REST	Aprobado
ML Lead	Diego	Responsible por dataset, features, modelo, calibración, export ONNX	Aprobado
Agentes IA	3× Claude Code 3× Cursor Pro	Responsible por implementación bajo tareas Cauce; sin autoridad de decisión arquitectónica	N/A

0.3 Bitácora de cambios / Change log

VERSIÓN	FECHA	CAMBIO	AUTOR
1.0	2026-09-11 21:00	Línea base inicial. Alcance, arquitectura, ADRs, requerimientos, plan y riesgos congelados para inicio de ejecución.	Paul

Regla de control de cambios: cualquier modificación a §4 (ADRs), §5–6 (requerimientos) o §8 (contrato de API) después de la Fase F1 requiere acuerdo explícito de los tres integrantes y entrada en esta bitácora. Cambios en §16 (supuestos) se registran en cuanto los jueces respondan.

0.4 Índice / Contents

1	Resumen ejecutivo
2	Contexto, problema y criterio de éxito
3	Alcance: dentro, fuera y priorización MoSCoW
4	Registro de decisiones de arquitectura (ADR-001 ... ADR-013)
5	Requerimientos funcionales (FR)
6	Requerimientos no funcionales (NFR)
7	Arquitectura del sistema
8	Contrato de API
9	Catálogo de features conversacionales
10	Plan de datos y modelo
11	Especificación de frontend
12	Integraciones de patrocinadores
13	Plan de trabajo, Cauce y cronograma
14	Definition of Done por criterio de evaluación
15	Registro de riesgos
16	Supuestos provisionales (decisiones sujetas a confirmación)
17	Preguntas abiertas para los jueces de Altur
18	Anexos: runbook, variables de entorno, checklist pre-judging

1 Resumen ejecutivo

Concorde es una capa de confianza para el canal telefónico bancario: recibe una llamada grabada entre un cliente y un agente de voz, y determina si quien llama es una persona real o una voz sintética. El entregable evaluable es un endpoint `POST /detect` que responde `{"is_synthetic": bool, "confidence": float}`, respaldado por un dashboard operativo que demuestra que el sistema es auditable y desplegable, no solo preciso.

La tesis técnica del proyecto es deliberadamente contraria a la ruta obvia. La mayoría de los equipos entrenará un clasificador acústico sobre la forma de onda. Nosotros apostamos por la señal **conversacional (behavioral)** como núcleo: el propio documento de Altur señala que el agente interrumpe, calla y habla encima del interlocutor a propósito, y que «*los humanos se recuperan de eso al instante y de forma desordenada; las máquinas se recuperan de forma consistente, y la consistencia es una señal*». Esa pista está explícitamente puesta sobre la mesa y está infrautilizada. Además, es la única de las tres rutas que explota el hecho de que se entregan **ambos canales** del audio — algo que Altur subraya dos veces en su documento.

Tres consecuencias de diseño se derivan de esa tesis y ordenan todo lo demás:

1. **Generalización sobre precisión aparente.** El conjunto oculto de evaluación usa hablantes y motores de voz que no aparecen ni en `train` ni en `val`. Un modelo acústico profundo sobre ~300 llamadas memoriza artefactos del motor TTS específico y colapsa ante uno nuevo. Las features conversacionales son de mucha menor dimensión y capturan una propiedad estructural del turno de habla, no una huella de vocoder.
2. **El endpoint es un sistema de producción, no un notebook.** Se evalúa latencia, robustez y viabilidad de despliegue. Se construye en Rust, con presupuesto de latencia explícito, degradación elegante y la garantía de no emitir jamás un 5xx.
3. **La explicabilidad es parte del producto.** Un banco no adopta un veredicto binario sin justificación. Concorde expone, por llamada, qué señales dispararon la decisión y con qué peso.

Hallazgo crítico detectado en fase de análisis — condiciona la arquitectura

El dataset entrega `turns/<anon_id>.json` con los segmentos de habla ya calculados por canal, pero `/detect` recibe únicamente el WAV. Los jueces no enviarán ese JSON. Por lo tanto, el sistema **debe incluir su propio detector de actividad de voz (VAD) en la ruta de inferencia**, y ese VAD debe validarse contra los `turns.json` provistos para garantizar que las features calculadas en producción son consistentes con las usadas en entrenamiento. Omitir esto produce un sistema que funciona en local y falla en la ronda automatizada. Ver ADR-003, FR-004 y R-01.

EN — EXECUTIVE SUMMARY

Concorde is a trust layer for the banking phone channel: it takes a recorded call between a customer and a voice agent and decides whether the caller is a real person or a synthetic voice. The scored deliverable is a `POST /detect` endpoint returning `{"is_synthetic": bool, "confidence": float}`, backed by an operator dashboard that shows the system is auditable and deployable, not merely accurate.

The technical thesis is deliberately against the obvious route. Most teams will train an acoustic classifier on the waveform. We make the **conversational (behavioral)** signal the core: Altur's own brief states the agent interrupts, falls silent and talks over the caller on purpose, and that humans recover instantly and messily while machines recover consistently — consistency being the signal. That hint is explicit and underused, and it is the only one of the three routes that exploits the fact that **both channels** are provided, something Altur emphasises twice.

Three design consequences follow: generalisation is prioritised over apparent accuracy, because the hidden set uses unseen speakers and engines; the endpoint is treated as a production service with an explicit latency budget, graceful degradation and a no-5xx guarantee; and explainability is part of the product, because a bank will not adopt an unjustified binary verdict.

Critical finding: the dataset ships pre-computed speech turns, but `/detect` receives only the WAV. The system must therefore run its own VAD in the inference path, validated against the provided turn files so that production features match training features. See ADR-003, FR-004, R-01.

2 Contexto, problema y criterio de éxito

2.1 Contexto de negocio

Altur opera agentes de voz con IA para las mayores instituciones financieras de Latinoamérica: más de 150 millones de llamadas originadas por mes, más de 3 millones de conversaciones en vivo mensuales, en seis países. El canal telefónico es la puerta de entrada del banco y hoy es atacable en dos direcciones: suplantar al cliente para tomar control de una cuenta, y suplantar al banco para extraer credenciales por ingeniería social. La población más expuesta es la que opera por teléfono porque no puede o no usa aplicaciones — es decir, la que no tiene canal alternativo. Ese es el argumento de impacto del proyecto y el cierre natural del pitch.

2.2 Definición formal del problema

Dado un archivo WAV estéreo de 8 kHz y 16 bits PCM, donde el canal 0 corresponde al interlocutor entrante y el canal 1 al agente del banco, emitir una decisión binaria sobre el canal 0 (*humano* vs. *sintético*) acompañada de una confianza calibrada en `[0,1]`, dentro de un presupuesto de latencia compatible con operación telefónica.

2.3 Criterio de éxito

NIVEL	DEFINICIÓN
Mínimo	Endpoint <code>/detect</code> desplegado, alcanzable y estable durante las 4 h de judging, devolviendo veredictos válidos con desempeño superior al azar de forma demostrable sobre <code>val</code> .
Objetivo	Lo anterior + señal behavioral entrenada y calibrada ($AUC \geq 0.90$ en <code>val</code>), dashboard operativo con explicabilidad por llamada, y demo en vivo con audio no visto.
Sobresaliente	Lo anterior + capa semántica activa, registro de eventos en Tiger Data, demo «red team» con voces generadas por nosotros, y caso de negocio cuantificado.

EN — CONTEXT & SUCCESS CRITERIA

Altur runs AI voice agents for Latin America's largest financial institutions: 150M+ calls originated monthly, 3M+ live conversations monthly, across six countries. The phone line is the bank's front door and is attacked in both directions — impersonating customers to take over accounts, and impersonating the bank to social-engineer credentials. The most exposed population is the one that banks by phone because it cannot or does not use apps, i.e. the one with no alternative channel.

Problem. Given a stereo 8 kHz 16-bit PCM WAV where channel 0 is the incoming caller and channel 1 is the bank agent, emit a binary verdict on channel 0 with a calibrated confidence in $[0,1]$, within a latency budget compatible with telephony operation.

Success. Minimum: endpoint deployed, reachable and stable throughout the 4-hour judging window, returning valid verdicts demonstrably better than chance on `val`. Target: adds a trained, calibrated behavioral model ($\text{val } AUC \geq 0.90$), an operator dashboard with per-call explainability, and a live demo on unseen audio. Outstanding: adds the semantic layer, Tiger Data event logging, a red-team demo with voices we generate ourselves, and a quantified business case.

3 Alcance: dentro, fuera y priorización MoSCoW

La priorización es vinculante. Un elemento de prioridad inferior **no** se inicia mientras exista uno de prioridad superior incompleto, salvo que esté bloqueado por dependencia externa. Esta regla existe porque la ventana real es de ~37 h y el modo de fallo más común en hackathones es dispersión, no incompetencia. Altur lo dice de forma explícita en su documento: «*depth beats breadth — one signal, done well, will outscore three that half-work*».

PRIORIDAD	ELEMENTO	JUSTIFICACIÓN / CRITERIO DE CORTE
MUST	Endpoint <code>/detect</code> con parsing defensivo, VAD propio, features behavioral, modelo e inferencia ONNX	Es el único artefacto puntuado automáticamente. Sin esto no hay proyecto.
MUST	Despliegue en Vultr alcanzable y estable durante judging	Requisito explícito del reto: «your endpoint must be reachable throughout judging».
MUST	Calibración de <code>confidence</code>	Altur declara que la usa para desempatar y premiar sistemas bien calibrados.
MUST	<code>README.md</code> explicando el enfoque	Pedido explícitamente en el documento del reto.
SHOULD	Dashboard operativo con explicabilidad por llamada	Ataca Feasibility y Technical depth. Es el diferenciador visible en 15 min de judging.
SHOULD	Endpoint <code>/analyze</code> (superset explicativo) y <code>/health</code>	Separa el contrato mínimo del grader de la riqueza que necesita el dashboard. Ver ADR-013.
SHOULD	Capa semántica vía Gemini, con timeout duro y degradación	Alta originalidad, bajo costo incremental. Nunca puede poner en riesgo la latencia.
SHOULD	Demo «red team» con clips generados por ElevenLabs	Prueba Robustness de forma demostrable ante el juez, no declarativa.
COULD	Registro de eventos en Tiger Data + vista histórica	Premio de patrocinador + narrativa de observabilidad. No bloqueante.
COULD	Señal acústica como tercer voto	Solo si el núcleo está cerrado y queda margen antes del congelamiento.
COULD	Protocolo de escalamiento (defensa activa documentada)	Se entrega como diseño y narrativa en el pitch aunque no se implemente.
COULD	Dominio <code>.tech</code>	Esfuerzo trivial; se ejecuta en la fase de congelamiento, nunca antes.
WON'T	Solana / blockchain	Sin encaje causal con el problema. Integrarlo restaría credibilidad técnica.
WON'T	Snowflake	Redundante con Gemini (LLM) y Tiger Data (almacenamiento). Duplicaría infraestructura.
WON'T	MongoDB Atlas	Se elige Tiger Data; mantener ambos duplica trabajo de infraestructura sin premio adicional proporcional.
WON'T	Entrenamiento de red profunda desde cero	~300 llamadas. Riesgo de sobreajuste incompatible con el criterio de Robustness. Ver ADR-002.
WON'T	Reentrenamiento en línea / aprendizaje continuo	Fuera de ventana temporal. Se menciona solo como roadmap.

Prioritisation is binding: no lower-priority item starts while a higher-priority item is incomplete, unless externally blocked. With a ~37-hour window, the dominant failure mode is dispersion, not incompetence — and Altur states it directly: depth beats breadth.

MUST: `/detect` with defensive parsing, own VAD, behavioral features, ONNX inference; stable Vultr deployment through judging; calibrated confidence; README. **SHOULD:** operator dashboard with per-call explainability; `/analyze` and `/health`; Gemini semantic layer behind a hard timeout; ElevenLabs red-team demo. **COULD:** Tiger Data event logging; acoustic signal as a third vote; documented active-defence escalation protocol; `.tech` domain. **WON'T:** Solana, Snowflake, MongoDB Atlas, deep networks trained from scratch, online retraining.

4 Registro de decisiones de arquitectura (ADR)

Cada decisión queda registrada con contexto, decisión, consecuencias y alternativas rechazadas. Este registro es la respuesta directa al criterio de evaluación *Technical depth*: «does the team understand why it works?». Está redactado para ser citable frente al jurado.

ADR-001 — Rust (Axum) como lenguaje del servicio de inferencia

Contexto	Se requiere baja latencia y estabilidad absoluta durante 4 h de judging. El código será escrito mayoritariamente por agentes de IA trabajando en paralelo sobre ramas independientes.
Decisión	Rust + Axum, con <code>hound</code> (WAV), <code>ort</code> (ONNX Runtime), <code>tokio</code> , <code>serde</code> , <code>tracing</code> .
Consecuencias	(+) Errores de memoria y de integración entre ramas se detectan en compilación, no en producción frente al juez. (+) Rendimiento equivalente a C++ en benchmarks de servidores HTTP. (–) Curva de aprendizaje; se mitiga con agentes y con alcance acotado del código Rust a extracción de features + serving.
Alternativas	C++ (<i>Drogon/Crow</i>): rechazado — mismo rendimiento, pero mayor superficie de fallo en runtime con generación asistida por IA y mayor costo de boilerplate (WAV, JSON, HTTP). Python (<i>FastAPI</i>): rechazado como ruta principal por latencia y por debilidad narrativa frente al criterio de Feasibility.
Estado	Aceptado

ADR-002 — Gradient boosting sobre features tabulares, no red profunda sobre audio

Contexto	~300 llamadas etiquetadas; <code>train</code> / <code>val</code> disjuntos por hablante; el conjunto oculto usa hablantes y <i>motores de voz</i> ausentes de ambos splits.
Decisión	LightGBM (o XGBoost) sobre el catálogo de features de \$9, exportado a ONNX.
Consecuencias	(+) Generaliza mejor con pocos datos. (+) Entrena en segundos, permitiendo muchas iteraciones en la ventana disponible. (+) <code>feature_importance</code> y SHAP alimentan directamente la capa de explicabilidad sin trabajo extra. (–) Techo de desempeño menor que un modelo acústico bien entrenado con datos abundantes — que no es nuestro caso.
Alternativas	CNN/ <i>transformer sobre espectrograma</i> : rechazado por sobreajuste al motor TTS específico del dataset. <i>Fine-tuning de modelo anti-spoofing preentrenado</i> : reservado como COULD para la señal acústica opcional, no como núcleo.
Estado	Aceptado

ADR-003 — VAD propio obligatorio en la ruta de inferencia

Contexto	<code>turns/*.json</code> existe solo en el dataset de práctica. <code>/detect</code> recibe exclusivamente el WAV.
Decisión	Implementar segmentación de habla por canal en Rust (energía RMS + umbral adaptativo + histéresis + suavizado de duración mínima), produciendo la <i>misma estructura</i> que <code>turns.json</code> . Validar contra los archivos provistos antes de entrenar.
Consecuencias	(+) Elimina la brecha entrenamiento-inferencia (<i>training/serving skew</i>), que es el riesgo silencioso número uno del reto. (–) Requiere una tarea dedicada y su validación; se prioriza como MUST en F1.
Alternativas	<i>Entrenar con <code>turns.json</code> y esperar que el VAD de producción coincida</i> : rechazado — es exactamente el fallo que produce buen resultado local y colapso en la ronda automatizada.
Estado	Aceptado — bloqueante

ADR-004 — ONNX como frontera entre entrenamiento y serving

Contexto	El modelo se entrena en Python (iteración rápida) pero se sirve en Rust (latencia).
Decisión	El modelo entrenado y el calibrador se exportan a un único artefacto ONNX versionado. Rust carga el artefacto al arranque y no depende de Python en tiempo de ejecución.
Consecuencias	(+) Desacopla los flujos de trabajo de Diego y Paul: pueden avanzar en paralelo contra un contrato de tensor fijo. (+) Sin proceso Python en producción: menos superficie de fallo. (–) El contrato de features (orden y tipo del vector) debe congelarse temprano y versionarse — ver FR-006.
Estado	Aceptado

ADR-005 — Behavioral como señal primaria; profundidad sobre amplitud

Contexto	Altur propone tres rutas (acústica, conversacional, semántica) y declara que una señal bien ejecutada supera a tres a medias.
Decisión	Behavioral es el núcleo y la única señal cuya ausencia bloquea la entrega. Semantic y Acoustic son aditivas y opcionales.
Consecuencias	(+) Explota ambos canales, que Altur señala como infrautilizados. (+) Máxima puntuación esperada en Originality: no es un clasificador de audio de estantería. (–) Si el dataset resultara pobre en eventos de interrupción, la señal se debilita; mitigado por R-04 y verificado en F0 mediante EDA.
Estado	Aceptado

ADR-006 — Semántica fail-safe del endpoint: nunca 5xx

Contexto	Un error de servidor durante el benchmark probablemente se contabiliza como fallo total del caso, no como abstención.
Decisión	<code>/detect</code> siempre responde <code>200</code> con un cuerpo válido. Ante entrada inválida, audio ilegible o fallo interno, devuelve el veredicto de respaldo con <code>confidence</code> baja y registra el incidente internamente.
Consecuencias	(+) Ningún caso del conjunto oculto se pierde por una excepción no prevista. (–) Requiere disciplina de logging para no enmascarar errores reales durante el desarrollo: en entorno de desarrollo los fallos sí se propagan (<code>CONCORDE_STRICT=1</code>).
Estado	Aceptado

ADR-007 — Tiger Data (PostgreSQL) para registro de eventos

Contexto	Se requiere persistencia para la vista histórica del dashboard y opta a premio de patrocinador. MongoDB Atlas ofrecía premio equivalente.
Decisión	Tiger Data, por compatibilidad PostgreSQL: <code>sqlx / tokio-postgres</code> son drivers maduros en Rust, y las <i>continuous aggregates</i> encajan con series temporales de detecciones.
Consecuencias	(+) Cero fricción con el stack Rust. (+) Narrativa coherente: métricas de detección son series de tiempo por naturaleza. (–) Se renuncia al premio de MongoDB; decisión consciente para no duplicar infraestructura.
Estado	Aceptado

ADR-008 — Capa semántica acotada en tiempo y degradable

Contexto	La señal semántica requiere transcripción y una llamada a un LLM externo. La latencia es criterio de evaluación explícito.
Decisión	La semántica se ejecuta con <i>timeout duro</i> (ver NFR-001). Si vence el plazo o falla la API, el veredicto se emite solo con la señal behavioral, marcando internamente <code>semantic_available=false</code> . La semántica nunca es camino crítico.
Consecuencias	(+) Un incidente de red con un proveedor externo no puede tumbar la evaluación. (–) El modelo debe ser capaz de operar con el subconjunto behavioral puro; se entrenan dos variantes o se imputa el valor faltante de forma explícita.
Estado	Aceptado

ADR-009 — Parsing defensivo multi-forma de la petición

Contexto	El reto especifica «stereo WAV clip, base64-encoded» pero no define el nombre del campo ni el envoltorio (cuerpo crudo, JSON con clave, multipart). Esta es la ambigüedad de mayor impacto del reto: equivocarse implica cero puntos con un sistema perfecto.
Decisión	<code>/detect</code> acepta todas las formas plausibles: cuerpo base64 crudo; JSON con cualquiera de <code>audio</code> , <code>audio_base64</code> , <code>wav</code> , <code>data</code> , <code>file</code> , <code>clip</code> , <code>content</code> ; <code>multipart/form-data</code> ; y WAV binario directo. Tolerar prefijos <i>data-URI</i> y base64 con y sin relleno.
Consecuencias	(+) Inmunidad total a esta ambigüedad. (–) ~60 líneas extra de parsing; costo despreciable frente al riesgo cubierto. Se confirmará con los jueces (\$17, Q-01) y se conservará el parser flexible aun conociendo la respuesta.
Estado	Aceptado

ADR-010 — Despliegue en Vultr con proxy inverso y TLS

Contexto	El endpoint debe ser alcanzable externamente y estable 4 h. Se desconoce si el harness exige HTTPS.
Decisión	Instancia Vultr con el binario Rust bajo <code>systemd</code> y Caddy como proxy inverso, sirviendo simultáneamente HTTP (:80) y HTTPS (:443) con certificado automático. Se expone además una IP y un nombre DNS.
Consecuencias	(+) Cubre ambos escenarios sin depender de la respuesta a Q-05. (+) <code>systemd</code> reinicia el servicio ante caída. (–) Un componente más que configurar; se ejecuta en F1, no en la última hora.
Estado	Aceptado

ADR-011 — Cauce como orquestador de trabajo paralelo

Contexto	Tres personas y seis agentes de codificación sobre un mismo repositorio durante 37 h.
Decisión	Coordinación mediante Cauce: <code>tasks.yaml</code> versionado, <i>scopes</i> de archivos no solapados, <i>worktrees</i> por tarea y <i>test-merge</i> previo a la integración. Prohibido editar <code>tasks.yaml</code> a mano.
Consecuencias	(+) Elimina conflictos de merge como clase de problema. (+) Trazabilidad de quién hizo qué, útil para el juicio de <i>technical depth</i> . (–) Disciplina obligatoria: toda tarea debe declarar <code>scope</code> preciso.
Estado	Aceptado

ADR-012 — Disciplina de validación: `val` es intocable

Contexto	Los splits son disjuntos por hablante por diseño. El conjunto oculto añade motores de voz nuevos.
Decisión	El split <code>val</code> se usa exclusivamente para medición final y calibración, nunca para selección iterativa de hiperparámetros. La selección de modelo se hace con validación cruzada agrupada por hablante <i>dentro</i> de <code>train</code> .
Consecuencias	(+) La métrica reportada al jurado es honesta y defendible bajo preguntas. (-) Menos datos efectivos para ajuste; aceptado conscientemente.
Estado	Aceptado

ADR-013 — Separación entre contrato mínimo y payload explicativo

Contexto	El dashboard necesita información rica por llamada; el grader automático espera un esquema específico. Añadir campos extra a la respuesta puntuada introduce riesgo innecesario ante un parser estricto.
Decisión	<code>/detect</code> devuelve exclusivamente <code>is_synthetic</code> y <code>confidence</code> . Toda la información explicativa se expone en <code>POST /analyze</code> , consumido únicamente por nuestro frontend.
Consecuencias	(+) Riesgo cero de romper el contrato puntuado. (+) Libertad total para enriquecer <code>/analyze</code> . (-) Dos rutas que comparten el mismo pipeline interno; se implementa una función de análisis y dos serializadores.
Estado	Aceptado

EN — ARCHITECTURE DECISIONS, SUMMARY

ADR-001 Rust/Axum over C++: equal performance, but compile-time capture of memory and cross-branch integration errors, which matters when six AI agents write code in parallel. **ADR-002** Gradient boosting over tabular features rather than a deep audio network: ~300 labelled calls and a hidden set with unseen TTS engines make overfitting the dominant risk; feature importance also feeds explainability for free. **ADR-003** Own VAD is mandatory in the inference path, validated against the provided turn files, to eliminate training/serving skew. **ADR-004** ONNX is the training/serving boundary, decoupling Diego's and Paul's workstreams behind a frozen tensor contract. **ADR-005** Behavioral is the primary signal; depth over breadth. **ADR-006** The endpoint never returns 5xx. **ADR-007** Tiger Data over MongoDB, for Postgres-compatible Rust drivers and time-series fit. **ADR-008** The semantic layer is hard-timeout-bounded and degrades gracefully; it is never on the critical path. **ADR-009** Defensive multi-shape request parsing, because the brief does not define the request field name — the highest-impact ambiguity in the challenge. **ADR-010** Vultr + Caddy serving both HTTP and HTTPS, so the answer to Q-05 cannot hurt us. **ADR-011** Cause for parallel agent orchestration. **ADR-012** `val` is reserved for final measurement and calibration only. **ADR-013** `/detect` returns the minimal scored contract; all explanatory data lives in `/analyze`.

5 Functional requirements (FR)

Normative. *Shall* = binding. Each requirement is verifiable; the Verification column states how it is proven done.

ID	PRI	REQUIREMENT	VERIFICATION
FR-001	MUST	The service shall expose <code>POST /detect</code> accepting a stereo 8 kHz 16-bit PCM WAV clip, base64-encoded, where channel 0 is the caller and channel 1 is the agent.	Integration test posting a known <code>val</code> clip returns HTTP 200 with a valid body.
FR-002	MUST	The <code>/detect</code> response body shall be exactly <code>{"is_synthetic": <bool>, "confidence": <float in [0,1]>}</code> with no additional keys.	Schema assertion in CI over 20 sample responses; key-set equality check.
FR-003	MUST	Request parsing shall accept, without configuration: (a) raw base64 body; (b) JSON object with any key in <code>{ audio , audio_base64 , wav , data , file , clip , content }</code> ; (c) <code>multipart/form-data</code> with any single file part; (d) raw binary WAV body. Data-URI prefixes and unpadded base64 shall be tolerated.	Parametrised test suite covering all 4 shapes $\times$ padded/unpadded $\times$ with/without data-URI prefix.
FR-004	MUST	The service shall compute speech turns per channel at inference time using its own VAD, emitting the same structure as <code>turns/<id>.json</code> . The VAD shall be validated against the provided turn files before the model is trained.	Agreement report vs. provided turns on ≥ 30 calls: per-frame F1 ≥ 0.85 and turn-count ratio within $\pm 20\%$.
FR-005	MUST	The service shall compute the behavioral feature vector defined in §9, in the exact order declared by the frozen feature contract.	Golden-vector test: Rust extractor and Python extractor produce identical vectors (tolerance 1e-6) on 10 fixed calls.
FR-006	MUST	Inference shall run a versioned ONNX artifact loaded once at process start. The artifact shall embed or be accompanied by a feature-contract version string; a mismatch shall abort startup.	Startup log shows <code>model_version</code> ; deliberately mismatched contract fails to boot.
FR-007	MUST	The emitted <code>confidence</code> shall be a calibrated probability of the positive class (<code>is_synthetic = true</code>), not a raw model score. <code>is_synthetic</code> shall be derived from a documented threshold.	Reliability curve and Brier score on <code>val</code> reported in the README; threshold recorded in config.
FR-008	MUST	On unparseable, malformed, empty, mono, wrong-rate or otherwise invalid input, the service shall still return HTTP 200 with a valid fallback verdict and shall record the incident in structured logs.	Fault-injection suite: truncated WAV, zero bytes, mono file, 44.1 kHz file, non-audio blob, 40 MB blob.
FR-009	SHOULD	The service shall expose <code>POST /analyze</code> returning the superset payload: verdict, per-signal sub-scores, feature values, top contributing features with direction, detected turns, overlap events, and a natural-language rationale.	Dashboard renders a full call detail view driven solely by this endpoint.
FR-010	MUST	The service shall expose <code>GET /health</code> returning liveness, <code>model_version</code> , git SHA, uptime and dependency status.	Curl during judging window returns 200 with populated fields.
FR-011	SHOULD	The service shall expose <code>GET /metrics</code> with request count, error count, and latency percentiles (p50/p95/p99) segmented by outcome.	Metrics visible in the dashboard's operations panel.
FR-012	SHOULD	The dashboard shall provide three views: (1) live monitoring list of processed calls with verdict state; (2) per-call detail with dual-channel waveform, turn markers, confidence-over-time trace and signal breakdown; (3) executive view with aggregate operational and business metrics.	Walkthrough rehearsal: all three views reachable in under 20 seconds from landing.
FR-013	SHOULD	The dashboard shall allow uploading an arbitrary WAV and display the verdict live, enabling demonstration on audio absent from both splits.	Live demo with an ElevenLabs-generated clip and a freshly recorded human clip.
FR-014	SHOULD	The semantic sub-signal shall evaluate caller responses for invention of non-existent information and for template-like answering, using an LLM under a hard timeout, contributing an additional feature to the model.	A/B measurement on <code>val</code> : AUC with and without the semantic feature, reported in the README.
FR-015	COULD	Each verdict event shall be persisted with timestamp, latency, sub-scores, model version and outcome, and be queryable for the historical dashboard view.	Historical chart renders from stored events after a replay run over <code>val</code> .
FR-016	MUST	The repository shall contain a <code>README.md</code> in English explaining the approach, the signals used, measured results, and how to run the system.	Reviewed and signed off by all three members before code freeze.

6 Non-functional requirements (NFR)

ID	ATTRIBUTE	REQUIREMENT AND RATIONALE
NFR-001	Latency	End-to-end <code>/detect</code> latency for a 180 s clip: p95 ≤ 3.0 s, p99 ≤ 5.0 s , measured server-side excluding network transfer. Internal budget: decode + VAD ≤ 800 ms; feature extraction ≤ 400 ms; inference ≤ 50 ms; semantic layer hard timeout 1.5 s , cancelled and skipped on expiry. <i>Latency is an explicit judging criterion.</i>
NFR-002	Availability	100% reachability during 09:00–13:00 on 13 Sep 2026. Process supervised by <code>systemd</code> with <code>Restart=always</code> . A second instance on a distinct provider or port is prepared as cold standby, with the switch documented in §18.3.
NFR-003	Payload limits	Maximum accepted body: 32 MB . Derivation: $8000\text{ Hz} \times 2\text{ bytes} \times 2\text{ channels} = 32\text{ KB/s}$; a 600 s call is 19.2 MB raw, ≈ 25.6 MB base64. 32 MB therefore

		covers calls well beyond the observed maximum (273 s) with margin. Bodies above the limit are rejected before decoding to prevent trivial memory exhaustion.
NFR-004	Concurrency	The service shall sustain ≥ 8 concurrent <code>/detect</code> requests without exceeding NFR-001 p99. Rationale: the benchmark's concurrency is unknown (Q-04); 8 is a conservative safety factor over sequential evaluation.
NFR-005	Fault semantics	The service shall never emit 5xx on <code>/detect</code> (ADR-006). Any panic shall be caught at the handler boundary and converted into a fallback verdict. A panic shall never terminate the worker.
NFR-006	Resource ceiling	Resident memory ≤ 1.5 GB under sustained load; audio buffers streamed and released per request, never accumulated. Verified with a 30-minute soak test at 4 req/s.
NFR-007	Cold start	Process ready to serve ≤ 5 s after start, model preloaded. No lazy model loading on first request.
NFR-008	Observability	Structured JSON logs per request: request id, byte size, detected duration, turn count, per-stage timings, sub-scores, final verdict, model version. No audio content and no transcript text in logs.
NFR-009	Reproducibility	Every artifact records: git SHA, model version, training random seed, dataset manifest hash, feature-contract version. The reported metric must be reproducible from the repository by a third party.
NFR-010	Determinism	Identical input yields identical output, except when the semantic layer is active, in which case the behavioral-only verdict must remain deterministic and is what gets reported under degradation.
NFR-011	Security & data handling	No dataset files in the repository or in deployment artifacts. No PII persisted. Secrets only via environment variables, never committed. Basic rate limiting on public endpoints. No speaker-identification functionality of any kind.
NFR-012	Frontend quality	The dashboard shall present as a production fintech console: deliberate type scale, information density appropriate to an operations tool, no default framework theming, dark-mode-first, legible on a 13-inch laptop at 1 $\times$ zoom during judging. It shall degrade to the last known state rather than showing an error screen if the backend is momentarily unreachable.

ES — NOTA SOBRE NFR-001 Y NFR-003

Los dos números que más se cuestionarán en el judging son el presupuesto de latencia y el límite de carga útil, y ambos están derivados, no inventados. El límite de 32 MB proviene del cálculo exacto de tasa de bits telefónica (32 KB/s) aplicado a una llamada de 600 s con sobrecoste de base64. El presupuesto de latencia asigna el mayor bloque a decodificación y VAD porque son las únicas etapas cuyo costo crece linealmente con la duración del audio; la inferencia del modelo tabular es despreciable (< 50 ms) y por eso la elección de ADR-002 también compra latencia, no solo generalización.

7 Arquitectura del sistema

7.1 Vista de componentes



7.2 Principios rectores

- **El camino puntuado es sagrado.** Todo lo que no sea indispensable para producir el veredicto se ejecuta fuera del camino crítico o de forma cancelable.
- **Una sola fuente de verdad para features.** El extractor de referencia en Python y el de producción en Rust se verifican por paridad de vectores dorados (FR-005). Si divergen, el sistema está roto aunque ambos «funcionen».
- **Degradación explícita, nunca silenciosa.** Cuando una señal no está disponible, el veredicto lo refleja internamente y queda registrado; nunca se sustituye por un valor inventado sin marcar.
- **El almacenamiento es observabilidad, no dependencia.** Si Tiger Data no está disponible, `/detect` sigue respondiendo con normalidad.

EN — GUIDING PRINCIPLES

The scored path is sacred: anything not strictly required to produce the verdict runs off the critical path or is cancellable. Features have a single source of truth, enforced by golden-vector parity between the Python reference extractor and the Rust production extractor — if they diverge, the system is broken even if both "work". Degradation is explicit and logged, never silently imputed. Storage is observability, not a dependency: if Tiger Data is down, `/detect` still answers normally.

8 API contract (normative)

8.1 POST /detect — scored contract

Request : any of the shapes in FR-003. Canonical form:
Content-Type: application/json
{ "audio_base64": "<base64 of stereo 8 kHz 16-bit PCM WAV>" }

Response : HTTP 200, Content-Type: application/json
{ "is_synthetic": true, "confidence": 0.87 }

Invariants

- HTTP status is ALWAYS 200 on this route (ADR-006 / NFR-005).
- Body contains EXACTLY these two keys, in this order, nothing else (ADR-013).
- is_synthetic : boolean. true = caller is a synthetic voice.
- confidence : float in [0.0, 1.0]. Calibrated $P(\text{is_synthetic} = \text{true})$. Reported for the asserted class; see 8.4.
- Fallback verdict on invalid input: { "is_synthetic": false, "confidence": 0.50 } rationale in 8.4.

8.2 POST /analyze — internal superset (dashboard only)

Response : HTTP 200

```
{
  "verdict": { "is_synthetic": true, "confidence": 0.87, "threshold": 0.50 },
  "signals": { "behavioral": 0.91, "semantic": 0.64, "acoustic": null },
  "degraded": { "semantic_available": true, "acoustic_available": false },
  "timeline": [ { "t": 34.0, "confidence": 0.55 }, { "t": 73.2, "confidence": 0.71 }, ... ],
  "turns": { "caller": [[10.5,20.16], ...], "agent": [[0.3,7.66], ...] },
  "events": [ { "type": "overlap", "t": 118.34, "duration": 0.42 }, ... ],
  "features": { "latency_cv": 0.11, "overlap_count": 3, ... },
  "top_factors": [ { "feature": "latency_cv", "value": 0.11,
    "direction": "synthetic", "weight": 0.28 }, ... ],
  "rationale": "Response latency was near-constant across 9 agent turns ...",
  "timings_ms": { "decode": 61, "vad": 240, "features": 88, "semantic": 910,
    "inference": 7, "total": 1306 },
  "meta": { "model_version": "concorde-b-1.3", "git_sha": "...",
    "feature_contract": "fc-1", "duration_s": 169.3 }
}
```

8.3 Auxiliary routes

ROUTE	PURPOSE AND RESPONSE
GET /health	{ "status": "ok", "model_version": "...", "git_sha": "...", "uptime_s": "...", "deps": { "tigerdata": "ok degraded", "gemini": "ok degraded" } } . Never depends on external services to return 200.
GET /metrics	Request counters and latency percentiles by outcome, JSON (and Prometheus text format if time allows).
GET /version	Build metadata for reproducibility audits (NFR-009).

8.4 Semantics of confidence and the fallback verdict

Interpretation. confidence is reported as the calibrated probability of the asserted class. When is_synthetic = true, it is $P(\text{synthetic})$; when false, it is $1 - P(\text{synthetic})$. This makes the value monotonic with certainty regardless of the verdict, which is the reading a tie-break mechanism most plausibly expects. This interpretation is a provisional decision — see §16, A-06.

Fallback. On invalid input the service asserts is_synthetic: false with confidence: 0.50. Rationale: 0.50 signals maximal uncertainty under either reading, and asserting the negative class avoids contributing a false positive — which, in a banking anti-fraud context, is the error type that damages legitimate customers and is therefore the one to bias against when the system genuinely knows nothing.

9 Behavioral feature catalog (normative)

Definitions below are the single source of truth for both the Python reference extractor and the Rust production extractor. Notation: C = caller turns (channel 0), A = agent turns (channel 1), each turn a half-open interval [start, end) in seconds. D = call duration. CV = coefficient of variation (σ/μ). All features are duration-agnostic aggregates, per NFR-001 and the variable call lengths observed (61 s – 273 s).

ID	FEATURE	DEFINITION	HYPOTHESIS (WHY IT SEPARATES)
F-01	resp_latency_mean	For every agent turn a and the first caller turn c with $c.start \geq a.end$: mean of $(c.start - a.end)$.	Machines answer after a near-constant pipeline delay (ASR endpointing + LLM + TTS). Humans vary with comprehension load.
F-02	resp_latency_median	Median of the same set. Robust to outliers.	
F-03	resp_latency_std	Standard deviation of the same set.	
F-04	resp_latency_cv	F-03 / F-01. Scale-free dispersion.	
F-05	latency_monotony_index	Fraction of response latencies falling within ± 0.15 s of the median latency.	Direct operationalisation of Altur's "consistency is a signal". Expected high for synthetic.
F-06	resp_latency_min	Minimum response latency.	Humans occasionally answer before the agent finishes; a strictly-serial pipeline rarely does.
F-07	overlap_count	Number of (a, c) pairs whose intervals intersect.	Barge-in and cross-talk are hallmarks of human turn-taking; many voice pipelines are half-duplex by construction.
F-08	overlap_rate_per_min	F-07 / ($D / 60$).	
F-09	overlap_total_dur	$\Sigma (\min(\text{ends}) - \max(\text{starts}))$ over intersecting pairs.	
F-10	caller_bargein_count	Count of caller turns starting strictly inside an ongoing agent turn.	The caller taking the floor unprompted; strongly human.
F-11	recovery_delay_mean	After each overlap event, mean time until the caller's next turn starts.	The core of ADR-005. Humans recover instantly and messily; machines recover uniformly.
F-12	recovery_delay_cv	CV of the same set.	
F-13	recovery_abort_ratio	Fraction of overlap events where the caller's turn ends within 0.4 s of overlap onset (i.e. yielded the floor).	
F-14	caller_turn_dur_mean	Mean duration of caller turns.	Synthetic turns cluster around generated-utterance lengths; human turn length is heavier-tailed.
F-15	caller_turn_dur_std	Standard deviation of caller turn durations.	
F-16	caller_turn_dur_cv	F-15 / F-14.	
F-17	short_turn_ratio	Fraction of caller turns with duration < 1.0 s.	Backchannels ("sí", "ajá", "okey"). Human conversation is full of them; scripted pipelines emit few.
F-18	fragmentation_rate	Count of consecutive same-channel caller turn pairs separated by a gap < 0.5 s, normalised per minute.	Self-repair and restarts. Visible in the sample file at 126.32–129.14 / 129.46–131.26.
F-19	caller_speech_ratio	Σ caller turn durations / D .	Floor-sharing balance differs between a scripted responder and a person.
F-20	speech_balance	Σ caller durations / Σ agent durations.	
F-21	silence_break_delay	For each mutual-silence gap > 2.0 s, time until the caller speaks; mean and CV (2 values).	When the agent deliberately falls silent, who breaks it and how fast is a strong behavioral tell.
F-22	turn_count_caller	Number of caller turns.	Normalising context for the ratios above; also guards against degenerate calls.
F-23	semantic_invention_score	SHOULD LLM-assessed probability that the caller supplied a confident answer to a request about non-existent information. Null when degraded.	Altur states a person says "I don't have that"; a language model tends to invent an answer.

Freezing rule: the feature contract (identifier `fC-1`, the ordered list F-01..F-22 plus optional F-23) is frozen at the end of phase F2. Any later addition creates `fC-2` and requires re-export of the ONNX artifact and a new golden-vector test. Silent reordering of the vector is the single most dangerous possible defect in this system: it produces plausible but wrong verdicts with no error raised.

Las 22 features obligatorias se agrupan en cinco familias: latencia de respuesta y su consistencia (F-01...F-06), solapamiento e interrupciones (F-07...F-10), recuperación tras la interrupción (F-11...F-13) — que es el corazón de la tesis del proyecto —, morfología del turno (F-14...F-18) y reparto del canal (F-19...F-22). F-05 y F-12 son las traducciones literales de la pista que Altur dejó en su documento: la consistencia es la señal. Si el modelo termina asignando peso alto a esas dos, la narrativa técnica del pitch se cierra sola.

10 Plan de datos y modelo

10.1 Dataset

~300 llamadas etiquetadas (`human` / `synthetic`), estéreo 8 kHz 16-bit PCM, con splits `train` / `val` disjuntos por hablante. Duraciones observadas entre 61 s y 273 s. El conjunto de juicio es oculto e incluye hablantes y motores de voz ausentes de ambos splits.

Acciones obligatorias en EDA (fase F0, responsable: Diego)

1. Confirmar el balance exacto de clases por split. La inspección preliminar del manifiesto sugiere predominio de `synthetic` ; si el desbalance supera 60/40, aplicar `class_weight` y reportar métricas insensibles a prevalencia (AUC, EER) además de exactitud.
2. Verificar densidad de eventos de solapamiento e interrupción por llamada. **Este es un gate de decisión:** si menos del 40% de las llamadas contiene al menos un evento de solapamiento, la familia F-07...F-13 pierde poder y se debe reforzar con F-01...F-06 y F-21 (ver R-04).
3. Comprobar que la duración no correlaciona con la etiqueta. Si lo hiciera, es un atajo espurio del dataset de práctica que no se sostendrá en el conjunto oculto: se excluye la duración como feature y se documenta la decisión.
4. Calcular el hash del manifiesto para trazabilidad (NFR-009).

10.2 Protocolo de entrenamiento y evaluación

ELEMENTO	DEFINICIÓN
Selección de modelo	Validación cruzada agrupada por hablante dentro de <code>train</code> . <code>val</code> no participa en la selección (ADR-012).
Algoritmo	LightGBM, profundidad limitada (≤ 4) y <code>min_data_in_leaf</code> alto, deliberadamente regularizado para privilegiar generalización sobre ajuste.
Calibración	Platt scaling o isotónica ajustada sobre <code>val</code> , evaluada por curva de fiabilidad, Brier score y ECE.
Métrica primaria	ROC-AUC en <code>val</code> . Objetivo: ≥ 0.90 .
Métricas secundarias	EER, exactitud al umbral elegido, Brier score (objetivo ≤ 0.12), matriz de confusión, y desglose de error por duración de llamada.
Umbral de decisión	Seleccionado sobre <code>train</code> (no <code>val</code>) optimizando coste asimétrico: un falso positivo (cliente legítimo bloqueado) se pondera por encima de un falso negativo, coherente con §8.4. El valor final se registra en configuración y se justifica en el README.
Prueba de robustez	Evaluación adicional sobre clips generados por nosotros con ElevenLabs, es decir, un motor de voz ausente del dataset. Es la aproximación más honesta disponible al conjunto oculto.

Regla anti-autoengaño

Una AUC de 0.99 en `val` con 22 features y ~250 ejemplos de entrenamiento debe tratarse como **señal de alarma, no de éxito**: es más probable que indique una fuga de información (por ejemplo, duración correlacionada con la etiqueta, o VAD que se comporta distinto según el tipo de voz) que un modelo genuinamente excelente. Ante ese resultado, el equipo está obligado a auditar features por importancia antes de continuar. El criterio de Robustness se evalúa con datos que no tenemos; la única defensa es el escepticismo metodológico.

~300 labelled calls, speaker-disjoint splits, judged on unseen speakers and engines. Mandatory EDA gates: confirm class balance and apply class weighting beyond 60/40; verify overlap-event density (if fewer than 40% of calls contain an overlap, the F-07...F-13 family weakens and latency plus silence-break features must carry more load); confirm duration does not correlate with the label, and drop it if it does, since that would be a practice-set shortcut that will not survive the hidden set; hash the manifest for traceability.

Model selection uses speaker-grouped cross-validation inside `train` only; `val` is reserved for final measurement and calibration. Deliberately regularised LightGBM, Platt/isotonic calibration, primary metric ROC-AUC with a ≥ 0.90 target, Brier ≤ 0.12 , threshold chosen with asymmetric cost favouring the avoidance of false positives. Robustness is additionally probed against ElevenLabs-generated voices, i.e. an engine absent from the dataset.

Anti-self-deception rule: a 0.99 val AUC with 22 features and ~250 training examples is an alarm, not a success — leakage is the likelier explanation, and the team is required to audit feature importances before proceeding.

11 Especificación de frontend — Concorde Console

Requisito rector (NFR-012): el dashboard debe leerse como una consola de operaciones de una empresa que procesa 150M+ llamadas al mes, no como un proyecto de hackathon. La referencia estética es el instrumental financiero serio — densidad de información alta, jerarquía tipográfica deliberada, cero temas por defecto de framework.

11.1 Sistema de diseño (vinculante para Néstor y los agentes)

TOKEN	DEFINICIÓN
Modo	Oscuro por defecto. Fondo base carbón azulado (no negro puro), superficies elevadas por luminancia, no por sombra.
Acento semántico	Tres estados y solo tres: <i>verificado</i> (verde frío), <i>revisión</i> (ámbar), <i>sintético</i> (rojo). El color nunca es el único portador de significado: siempre acompañado de etiqueta textual e icono, por accesibilidad y por proyección.
Tipografía	Una familia sans de interfaz con altura-x alta para densidad; cifras en variante tabular obligatoria en todas las tablas y métricas, para que las columnas numéricas alineen. Monoespaciada solo para identificadores y payloads.
Escala	Cuatro tamaños de texto como máximo. Jerarquía por peso y color antes que por tamaño.
Densidad	Alta: filas compactas, sin tarjetas infladas ni espaciado decorativo. Una consola de operaciones muestra muchas llamadas a la vez.
Movimiento	Solo funcional: actualización de estado en vivo y trazo de confianza. Nada decorativo.
Estados	Todo componente define sus estados de carga, vacío, error y degradado. La pantalla nunca queda en blanco.

11.2 Vistas

Vista 1 — Monitor en vivo

- Tabla densa de llamadas procesadas: id abreviado, duración, veredicto con estado semántico, confianza, latencia de proceso, marca temporal.
- Indicador de salud del servicio en cabecera: estado, versión de modelo, p95 actual, y estado de dependencias (semántica / almacenamiento) marcando degradación de forma visible.
- Actualización en vivo por WebSocket; *fallback* automático a sondeo si la conexión cae, sin mostrar error al usuario (NFR-012).

Vista 2 — Detalle de llamada (la pantalla que gana el judging)

- Forma de onda de **ambos canales** apilada y sincronizada, con marcadores verticales en cada evento de solapamiento, interrupción y silencio prolongado. Es la representación visual literal de la tesis del proyecto.
- Trazo de *confianza a lo largo de la llamada*, alineado temporalmente con la onda: el juez ve la decisión formándose turno a turno, lo que comunica «tiempo real» antes de que digamos una palabra.
- Desglose por señal (behavioral / semantic / acoustic) con disponibilidad explícita: una señal degradada se muestra como degradada, nunca como cero.
- Panel de factores principales: las features que más empujaron la decisión, con su valor, dirección y peso — alimentado por la importancia del modelo (FR-009).
- Explicación en lenguaje natural, una o dos frases, generada a partir de esos factores.

Vista 3 — Ejecutiva

- Métricas operativas agregadas: llamadas procesadas, distribución de veredictos, percentiles de latencia, tasa de degradación.
- Caso de negocio escalado a la operación real de Altur (150M+ llamadas/mes), con los supuestos **visibles en pantalla** y etiquetados como estimación. Un número sin su supuesto es una debilidad ante un jurado de ingenieros; un número con su supuesto es una conversación.
- Es la pantalla que queda abierta al terminar de hablar.

11.3 Zona de demostración

Carga de un WAV arbitrario con veredicto en vivo (FR-013), preparada para dos clips listos de antemano: uno humano grabado por nosotros y uno sintético generado con ElevenLabs — es decir, un motor de voz que el modelo nunca vio. Esta es la prueba *demonstrable* del criterio de Robustness, no declarativa.

EN — FRONTEND SPEC

Governing requirement: the console must read as the operations tool of a company handling 150M+ calls per month. Dark-mode-first, elevation by luminance, exactly three semantic states (verified / review / synthetic) never carried by colour alone, tabular figures everywhere, at most four type sizes, high row density, purely functional motion, and mandatory loading/empty/error/degraded states for every component.

Three views. *Live monitor*: dense table of processed calls plus a service-health header showing model version, current p95 and dependency degradation. *Call detail* — the screen that wins judging: both channels' waveforms stacked and time-synchronised with markers at every overlap, interruption and long silence; a confidence-over-time trace aligned to the waveform so the judge watches the decision form turn by turn; per-signal breakdown with explicit availability; top contributing factors with value, direction and weight; and a one-to-two sentence natural-language rationale. *Executive*: aggregate operational metrics and a business case scaled to Altur's real volume, with assumptions visible on screen and labelled as estimates.

A demo zone accepts an arbitrary WAV for a live verdict, prepared with one human clip we record and one ElevenLabs clip — an engine the model has never seen. That is demonstrable robustness rather than claimed robustness.

12 Integraciones de patrocinadores

PATROCINADOR	DECISIÓN	USO EN CONCORDE Y JUSTIFICACIÓN	DUEÑO
Vultr	MUST	Alojamiento del endpoint durante judging. Se requería infraestructura de todos modos; el crédito la cubre. Instancia + Caddy + systemd (ADR-010).	Paul
Gemini	SHOULD	Capa semántica (F-23): detección de invención de datos inexistentes y respuestas tipo plantilla. Variante de baja latencia obligatoria por NFR-001; timeout duro de 1.5 s.	Diego
ElevenLabs	SHOULD	Generación de clips sintéticos propios para la prueba de robustez y la demo «red team». Uso invertido y más interesante que el previsto por el patrocinador: lo usamos para atacar nuestro propio sistema.	Néstor
Tiger Data	COULD	Persistencia de <code>detection_events</code> y agregados continuos para la vista histórica (ADR-007). No bloqueante para <code>/detect</code> .	Paul
.Tech	COULD	Dominio del proyecto apuntando a la consola. Se ejecuta en la fase de congelamiento (F7), nunca antes.	Néstor
MongoDB Atlas	WON'T	Redundante con Tiger Data. Mantener dos almacenes duplica infraestructura sin retorno proporcional.	—
Snowflake	WON'T	Redundante con Gemini y Tiger Data.	—
Solana	WON'T	Sin relación causal con el problema. Integrarlo restaría credibilidad técnica ante un jurado de ingenieros de producción.	—

Regla de integración: ninguna integración de patrocinador puede introducirse en el camino crítico de `/detect`. Todas son aditivas, cancelables o están fuera del camino de respuesta. Un premio secundario nunca justifica arriesgar el criterio principal.

13 Plan de trabajo, Cauce y cronograma

13.1 Asignación y responsabilidad

PERSONA	DOMINIO	AUTORIDAD Y LÍMITES
Paul	Arquitectura, servicio Rust, despliegue, contrato de API	Decisión final sobre arquitectura y contrato. Custodio del congelamiento de código.
Néstor	Frontend, sistema de diseño, demo, clips de prueba	Decisión final sobre UX y presentación visual dentro de los tokens de §11.1.
Diego	Dataset, EDA, features de referencia, modelo, calibración, export ONNX	Decisión final sobre modelado dentro de los límites de ADR-002 y ADR-012.
Agentes IA	Implementación bajo tarea Cauce	Sin autoridad de decisión. Toda desviación del contrato de features o del contrato de API requiere aprobación humana explícita.

13.2 Tablero inicial de Cauce (`tasks.yaml`)

Los `scopes` están diseñados para no solaparse, condición necesaria para que Cauce permita reclamar tareas en paralelo sin conflicto. No editar `tasks.yaml` a mano bajo ninguna circunstancia (ADR-011).

ID	TASK	OWNER	DEPENDS	SCOPE (NON-OVERLAPPING)
T001	Repo skeleton, workspace, CI build, README stub	Paul	—	<code>Cargo.toml</code> , <code>.github/</code> , <code>README.md</code>
T002	EDA: class balance, overlap density, duration/label correlation, manifest hash	Diego	—	<code>ml/eda/</code>
T003	Vultr instance + Caddy + systemd unit + deploy script	Paul	—	<code>deploy/</code>
T004	Design tokens + app shell + routing	Néstor	—	<code>console/src/theme/</code> , <code>console/src/app/</code>
T005	Axum server, defensive request parser (FR-003), fail-safe handler (FR-008)	Paul	T001	<code>api/src/http/</code>
T006	WAV decode + channel split + input validation	Paul	T001	<code>api/src/audio/decode.rs</code>
T007	VAD in Rust producing turns.json-shaped output	Paul	T006	<code>api/src/audio/vad.rs</code>
T008	VAD agreement report vs provided turns (FR-004 gate)	Diego	T007	<code>ml/validation/vad_agreement/</code>
T009	Python reference feature extractor, F-01...F-22	Diego	T002	<code>ml/features/</code>
T010	Rust feature extractor, F-01...F-22, contract <code>fc-1</code>	Paul	T007	<code>api/src/features/</code>
T011	Golden-vector parity test Python ↔ Rust (FR-005)	Diego	T009,T010	<code>ml/validation/parity/</code>
T012	LightGBM training, grouped CV, calibration, metrics report	Diego	T009	<code>ml/train/</code>
T013	ONNX export + artifact versioning	Diego	T012	<code>ml/export/</code> , <code>artifacts/</code>
T014	<code>ort</code> integration, model load at boot, <code>/detect</code> wired end-to-end	Paul	T010,T013	<code>api/src/inference/</code>
T015	<code>/analyze</code> superset serializer + <code>/health</code> + <code>/metrics</code>	Paul	T014	<code>api/src/routes/</code>
T016	Live monitor view	Néstor	T004,T015	<code>console/src/views/live/</code>
T017	Call detail view: dual waveform, event markers, confidence trace, factors	Néstor	T004,T015	<code>console/src/views/detail/</code>
T018	Executive view + business case with visible assumptions	Néstor	T004	<code>console/src/views/exec/</code>
T019	Semantic probe: ASR + Gemini, hard timeout, degradation path (F-23)	Diego	T014	<code>api/src/semantic/</code> , <code>ml/semantic/</code>

T020	Tiger Data schema, event writer, historical aggregates	Paul	T015	api/src/storage/, deploy/sql/
T021	Red-team clip set: ElevenLabs synthetic + own human recordings	Néstor	T002	eval/redteam/
T022	Fault-injection + soak + concurrency test suite (NFR-001/004/005/006)	Paul	T014	api/tests/
T023	Final README: approach, signals, measured results, run instructions	All	T012,T022	README.md

13.3 Cronograma por fases (horas reales, CST)

FASE	VENTANA	OBJETIVO Y CRITERIO DE SALIDA
F0	11 sep · 20:00 – 21:30	Reconocimiento y arranque. Dataset descargado y verificado, EDA inicial (T002), <code>tasks.yaml</code> poblado, instancia Vultr provisionada. <i>Salida:</i> los tres gates de \$10.1 respondidos y el esqueleto del repo en <code>main</code> .
F1	11 sep 21:30 – 12 sep 02:00	Esqueleto vertical vivo. <code>/detect</code> desplegado y alcanzable públicamente devolviendo un veredicto de marcador de posición, con parser defensivo y VAD funcionando. <i>Salida crítica:</i> el endpoint responde desde internet antes de que exista modelo. Esto elimina el riesgo de despliegue del camino crítico, que es donde más equipos mueren.
F2	12 sep · 02:00 – 08:00	Señal real. Paridad de extractores (T011), modelo entrenado, calibrado y exportado, <code>/detect</code> sirviendo ONNX. <i>Salida:</i> contrato <code>fc-1</code> congelado; métrica de <code>val</code> reportada.
F3	12 sep · 08:00 – 14:00	Producto visible. <code>/analyze</code> y las vistas 1 y 2 de la consola funcionando contra el backend real. <i>Salida:</i> una llamada del split <code>val</code> es navegable de extremo a extremo en la interfaz.
F4	12 sep · 14:00 – 20:00	Diferenciadores. Capa semántica con degradación (T019), clips red-team (T021), Tiger Data (T020), vista ejecutiva (T018). <i>Salida:</i> cada elemento entra solo si no degrada NFR-001.
F5	12 sep 20:00 – 13 sep 02:00	Endurecimiento. Suite de inyección de fallos, prueba de concurrencia y soak (T022), despliegue final, medición de percentiles reales. <i>Salida:</i> todos los NFR verificados con evidencia, no con opinión.
F6	13 sep · 02:00 – 06:00	Colchón y ambición. Reservado para deuda descubierta en F5. Solo si todo está verde: señal acústica como tercer voto. <i>Regla:</i> nada nuevo entra después de las 05:00.
F7	13 sep · 06:00 – 09:00	Congelamiento y ensayo. Congelamiento de código a las 06:00 . README final (T023), dominio <code>.tech</code> , checklist de \$18.4, y tres pasadas completas del recorrido de 15 min con cronómetro.
–	13 sep · 09:00 – 13:00	Judging. Endpoint bajo supervisión activa: una persona designada vigila <code>/health</code> y logs durante toda la ventana; nadie toca el código desplegado bajo ninguna circunstancia.

Dos reglas de cronograma que no se negocian

(1) **Despliegue temprano.** El endpoint debe ser públicamente alcanzable al final de F1, con o sin modelo. Un sistema brillante no desplegado vale cero; un sistema mediocre desplegado y estable puntúa. (2) **Congelamiento a las 06:00.** Tres horas de margen antes del judging no son lujo: son el seguro contra el fallo más común y más evitable de todos, que es romper algo que funcionaba en la última hora.

13.4 Manejo del dataset

- El dataset se mantiene **fuera** del repositorio (`.gitignore` explícito para `audio/`, `turns/`, `manifest.csv` y cualquier derivado que contenga audio).
- No se incluye en imágenes ni artefactos de despliegue.
- No se implementa ninguna funcionalidad de identificación de hablantes.
- El `README.md` declara explícitamente el cumplimiento de estos términos. Es un detalle pequeño que comunica criterio profesional ante un jurado que trabaja con datos bancarios reales.

14 Definition of Done por criterio de evaluación

Los cinco criterios publicados por Altur se traducen aquí a evidencia verificable. La columna de evidencia es lo que se muestra o se dice literalmente durante los 15 minutos de judging.

CRITERIO	TERMINADO CUANDO...	EVIDENCIA MOSTRADA AL JURADO
Robustness	El sistema clasifica correctamente clips de un motor de voz ausente del dataset; el protocolo de validación excluye fuga por hablante; el desglose de error por duración no muestra colapso en ningún rango.	Demo en vivo con clip de ElevenLabs generado por nosotros + tabla de métricas con CV agrupada por hablante y umbral fijado sobre <code>train</code> .
Originality	La señal primaria no es un clasificador de audio de estantería, sino dinámica conversacional derivada de ambos canales; existe al menos una feature (F-05, F-12) que operacionaliza literalmente la pista del brief.	Vista de detalle mostrando marcadores de interrupción sobre ambas ondas, y el panel de factores señalando índices de consistencia entre los de mayor peso.
Technical depth	Cada decisión relevante tiene ADR con alternativas rechazadas; el skew entrenamiento/serving está eliminado por prueba de paridad; las métricas son reproducibles desde el repositorio.	Este documento (§4), la prueba de paridad de vectores dorados en verde, y la explicación de por qué <code>turns.json</code> no existe en inferencia — que demuestra que leímos el reto, no solo el título.
Feasibility	El servicio corre sobre audio telefónico real de 8 kHz, está desplegado con supervisión y TLS, expone salud y métricas, nunca falla con 5xx, y produce justificación auditable por llamada.	<code>/health</code> en vivo, panel de operaciones con percentiles reales, y el protocolo de escalamiento (verde / revisión / transferencia a agente humano de fraude).
Latency	p95 y p99 medidos y dentro de NFR-001, con presupuesto por etapa documentado y con la capa externa acotada por timeout duro.	Desglose <code>timings_ms</code> de una llamada real en pantalla + percentiles agregados en la vista ejecutiva.

EN — DEFINITION OF DONE

Robustness: correct classification of clips from an engine absent from the dataset, speaker-grouped validation, no error collapse in any duration band — evidenced by a live ElevenLabs demo and the metrics table. **Originality:** the primary signal is conversational dynamics across both channels, with features that literally operationalise the brief's own hint — evidenced by the interruption markers and the top-factors panel. **Technical depth:** every decision has an ADR with rejected alternatives, training/serving skew is eliminated by a parity test, metrics are reproducible from the repo — evidenced by this document and the green golden-vector test. **Feasibility:** runs on real 8 kHz telephony audio, deployed with supervision and TLS, exposes health and metrics, never 5xx, produces auditable per-call justification. **Latency:** measured p95/p99 within budget with per-stage accounting and a hard-bounded external call.

15 Registro de riesgos

P = probabilidad, I = impacto (1 bajo – 5 crítico). Se listan por exposición descendente.

ID	RIESGO	P	I	MITIGACIÓN (ACCIÓN CONCRETA, NO INTENCIÓN)	DUEÑO
R-01	Skew entrenamiento/serving: el modelo se entrena con <code>turns.json</code> pero inferencia usa VAD propio con comportamiento distinto.	Alta	5	ADR-003 + gate FR-004 + prueba de paridad T011 como tarea bloqueante antes de entrenar el modelo final.	Paul/Diego
R-02	Forma de la petición distinta a la asumida → cero puntos con sistema correcto.	Media	5	Parser multi-forma (ADR-009, FR-003) que cubre las cuatro formas plausibles, más pregunta Q-01 a los jueces en la primera oportunidad.	Paul
R-03	Sobreajuste al motor TTS del dataset; colapso ante motores nuevos del conjunto oculto.	Alta	4	ADR-002 (features de baja dimensión, modelo regularizado), ADR-012 (CV agrupada), evaluación contra clips ElevenLabs (T021), y la regla anti-autoengaño de §10.2.	Diego
R-04	Densidad de eventos de interrupción insuficiente en el dataset → la señal behavioral pierde poder.	Media	4	Gate de EDA en F0 (§10.1). Si <40% de llamadas tiene solapamiento, reponderar hacia F-01...F-06 y F-21 y elevar la capa semántica de SHOULD a MUST.	Diego
R-05	Caída del endpoint durante la ventana de judging.	Media	5	<code>systemd Restart=always</code> , congelamiento 06:00, instancia de respaldo en frío documentada (§18.3), y vigilancia humana activa de <code>/health</code> durante las 4 h.	Paul
R-06	La capa semántica introduce latencia o falla de red y arrastra al endpoint.	Media	3	ADR-008: timeout duro 1.5 s, cancelación, degradación marcada y veredicto behavioral-only determinista.	Diego
R-07	Divergencia entre ramas de agentes IA; integración tardía costosa.	Media	3	Cauce con scopes disjuntos (ADR-011), test-merge previo, y contratos congelados (<code>fc-1</code> y §8)	Paul
R-08	Reordenamiento silencioso del vector de features tras un cambio tardío.	Baja	5	Versión de contrato embebida en el artefacto; arranque aborta ante desajuste (FR-006). Es el defecto más peligroso posible: produce veredictos plausibles y erróneos sin error visible.	Paul
R-09	Agotamiento del equipo en las últimas horas y errores por fatiga.	Alta	3	Congelamiento a las 06:00 como regla dura; F6 es colchón, no fase de features; turnos de descanso escalonados durante F5.	Todos

R-10	Desbalance de clases no corregido → exactitud engañosa y umbral mal fijado.	Media	3	Gate de EDA, <code>class_weight</code> , métricas insensibles a prevalencia (AUC, EER) como primarias.	Diego
R-11	Llamadas atípicas en el conjunto oculto (muy cortas, un solo canal activo, silencio total).	Media	3	FR-008 + suite de inyección de fallos (T022) que incluye explícitamente esos casos; veredicto de respaldo definido en §8.4.	Paul
R-12	El dashboard consume tiempo del núcleo por ambición visual.	Media	2	Prioridad MoSCoW vinculante; las vistas 1 y 2 son SHOULD y no pueden iniciarse antes de cerrar F2.	Néstor

16 Supuestos provisionales — decisiones tomadas sin confirmación

Estatus de esta sección

Los supuestos siguientes se han **decidido para desbloquear la ejecución**, no porque exista certeza. Cada uno está diseñado para que su refutación cueste poco: la estrategia general ha sido cubrir ambos escenarios en lugar de apostar por uno. Cuando los jueces respondan (§17), esta sección se actualiza y la decisión final se registra en la bitácora de cambios §0.3.

These assumptions were decided to unblock execution, not because certainty exists. Each is designed to be cheap to refute: wherever possible we cover both scenarios instead of betting on one. They are updated as soon as the judges answer.

ID	SUPUESTO PROVISIONAL	DECISIÓN DE DISEÑO Y COSTO DE ESTAR EQUIVOCADOS
A-01	La petición llega como JSON con el audio en una clave de nombre desconocido, posiblemente como cuerpo base64 crudo o multipart.	Se aceptan las cuatro formas (ADR-009). Costo si es errónea: nulo , porque la implementación no depende del supuesto. Este es el supuesto de mayor riesgo del proyecto y por eso se neutraliza en vez de asumirse.
A-02	Los clips del conjunto oculto tienen duración comparable al dataset de práctica (61–273 s).	El sistema se dimensiona para hasta 600 s (NFR-003) y las features son agregados independientes de la duración. Costo si es errónea: bajo .
A-03	El harness de evaluación tolera al menos 10 s por petición.	Se fija un objetivo interno mucho más agresivo ($p95 \leq 3$ s) con presupuesto por etapa. Costo si es errónea: bajo , salvo que el timeout real fuera <3 s, en cuyo caso se desactiva la capa semántica mediante variable de entorno sin recompilar — conmutador previsto en §18.2.
A-04	El benchmark ejecuta peticiones de forma secuencial o con baja concurrencia.	Se dimensiona para ≥ 8 concurrentes (NFR-004) y se valida con prueba de carga. Costo si es errónea: bajo .
A-05	El harness puede llamar por HTTP simple; HTTPS podría ser requerido.	Se sirve simultáneamente HTTP y HTTPS con certificado automático (ADR-010), y se publica IP y nombre DNS. Costo si es errónea: nulo .
A-06	<code>confidence</code> se interpreta como probabilidad de la clase afirmada (§8.4).	Es la lectura que hace el valor monótono con la certeza bajo ambos veredictos, y la que un mecanismo de desempate esperaría. Costo si es errónea: medio — si Altur espera siempre $P(\text{synthetic})$, el cambio es de una línea y se aplica en minutos. Se pregunta explícitamente (Q-03).
A-07	Campos adicionales en la respuesta de <code>/detect</code> podrían romper un parser estricto.	Se separa el contrato mínimo del payload explicativo (ADR-013). Costo si es errónea: nulo ; solo se pierde la oportunidad de exhibir la explicación en la respuesta puntuada, que de todos modos se muestra en pantalla.
A-08	El conjunto oculto puede contener llamadas degeneradas (silencio, un solo canal, duración mínima).	Se asume que sí y se cubre con FR-008 y la suite de inyección de fallos. Costo si es errónea: nulo , solo trabajo defensivo no utilizado.

17 Preguntas abiertas para los ingenieros de Altur

Ordenadas por impacto. Las tres primeras justifican interrumpir a un ingeniero en cuanto esté disponible; las demás pueden esperar a la primera ronda de mentoría.
Ordered by impact; the first three justify approaching an engineer immediately.

ID	PREGUNTA (ES / EN)	POR QUÉ IMPORTA
Q-01	¿Cuál es la forma exacta del cuerpo de la petición a <code>/detect</code> ? ¿JSON con qué nombre de campo, base64 en el cuerpo crudo, o multipart? <i>What is the exact request body shape for <code>/detect</code> — JSON with which field name, raw base64 body, or multipart?</i>	Máximo impacto: un sistema perfecto puntúa cero si no lo acierta. Mitigado por ADR-009, pero confirmarlo permite además simplificar y probar el camino real.
Q-02	¿Qué timeout aplica su harness por petición, y cuántas peticiones corren contra cada equipo? <i>What per-request timeout does your harness apply, and how many requests are run against each team?</i>	Define si la capa semántica cabe en el presupuesto y si hay que dimensionar concurrencia.
Q-03	¿ <code>confidence</code> debe ser siempre $P(\text{sintético})$, o la probabilidad de la clase afirmada? <i>Should <code>confidence</code> always be $P(\text{synthetic})$, or the probability of the asserted class?</i>	Afecta directamente la calibración y el desempate. Cambio trivial, consecuencia no trivial.
Q-04	¿El conjunto oculto incluye llamadas fuera del rango de duración del dataset, o casos límite como un solo canal con habla? <i>Does the hidden set include calls outside the practice duration range, or edge cases such as a single active channel?</i>	Valida A-02 y A-08 y afina la suite de inyección de fallos.
Q-05	¿El endpoint debe servirse por HTTPS o basta HTTP? ¿Aceptan IP directa o requieren nombre DNS? <i>Must the endpoint be HTTPS, or is plain HTTP acceptable? Is a bare IP acceptable or is a DNS name required?</i>	Ya cubierto por ADR-010, pero conviene confirmarlo para simplificar la entrega.
Q-06	¿Cuántos motores de voz sintética distintos están representados entre el dataset de práctica y el conjunto oculto? <i>How many distinct synthetic voice engines are represented across the practice dataset and the hidden set?</i>	Es la pregunta que mejor calibra cuánto se debe desconfiar de la señal acústica frente a la conversacional.
Q-07	En su operación real, ¿qué error les cuesta más: dejar pasar una voz sintética o bloquear a un cliente legítimo? <i>In real operation, which error costs more: letting a synthetic voice through, or blocking a legitimate customer?</i>	Fija el umbral de decisión sobre criterio de negocio real en lugar de

una elección arbitraria — y es una pregunta que demuestra pensamiento de producto ante quien evalúa Feasibility.

18 Anexos operativos

18.1 Estructura del repositorio

concorde/	
├─ api/	Rust service (Axum)
│ └─ src/http/	defensive parser, routing, fail-safe handler
│ └─ src/audio/	decode.rs, vad.rs
│ └─ src/features/	fc-1 extractor (production)
│ └─ src/inference/	ort model loading + scoring
│ └─ src/semantic/	Gemini probe, hard timeout, degradation
│ └─ src/storage/	Tiger Data event writer (non-blocking)
│ └─ src/routes/	/detect /analyze /health /metrics /version
│ └─ tests/	fault injection, soak, concurrency
├─ ml/	Python (offline only, never in serving path)
│ └─ eda/	features/ train/ export/ semantic/
│ └─ validation/	vad_agreement/, parity/
├─ console/	React dashboard
│ └─ src/theme	src/app src/views/{live,detail,exec}
├─ eval/redteam/	generated + recorded probe clips (no dataset audio)
├─ deploy/	Caddyfile, systemd unit, deploy.sh, sql/
├─ artifacts/	versioned ONNX model + feature contract
├─ tasks.yaml	Cauce board – never hand-edit
└─ README.md	English, judge-facing

18.2 Variables de entorno

VARIABLE	FUNCIÓN
CONCORDE_MODEL_PATH	Ruta al artefacto ONNX. Ausente o incompatible ⇒ el arranque falla (FR-006).
CONCORDE_FEATURE_CONTRACT	Versión esperada del contrato de features (fc-1).
CONCORDE_THRESHOLD	Umbral de decisión. Ajustable sin recompilar.
CONCORDE_SEMANTIC_ENABLED	Conmutador de la capa semántica. Permite desactivarla en segundos si el timeout real resulta menor al asumido (A-03).
CONCORDE_SEMANTIC_TIMEOUT_MS	Timeout duro, por defecto 1500.
CONCORDE_MAX_BODY_BYTES	Límite de carga útil, por defecto 33554432 (32 MB).
CONCORDE_STRICT	Solo desarrollo: propaga errores en vez de degradar, para no enmascarar defectos.
GEMINI_API_KEY / TIGERDATA_URL	Credenciales. Nunca versionadas.

18.3 Procedimiento de contingencia del endpoint

1. Síntoma: /health no responde o devuelve estado no-ok.
2. systemd reinicia automáticamente; confirmar recuperación en ≤30 s vía log.
3. Si no recupera: desplegar el binario congelado en la instancia de respaldo en frío con el mismo artefacto ONNX (deploy/deploy.sh --standby).
4. Comunicar la nueva URL al jurado de inmediato si el cambio ocurre durante la ventana de evaluación.
5. Prohibido aplicar correcciones de código en caliente durante el judging. Solo se permite reiniciar, conmutar a respaldo o ajustar variables de entorno.

18.4 Checklist pre-judging (13 sep, 06:00–09:00)

VERIFICACIÓN		DUEÑO
☐	Código congelado; nada se mergea después de 06:00	Paul
☐	<code>/detect</code> responde correctamente desde una red externa al venue (probar desde datos móviles, no desde el WiFi del evento)	Paul
☐	Las cuatro formas de petición de FR-003 verificadas contra el despliegue final	Paul
☐	Suite de inyección de fallos en verde contra producción, no contra local	Paul
☐	p95/p99 medidos sobre el despliegue final y anotados para citarlos de memoria	Paul
☐	Consola cargada, con datos, y las tres vistas navegables sin recargar	Néstor
☐	Clips de demo (humano + ElevenLabs) probados en el equipo que se usará en la mesa	Néstor
☐	Métricas finales de <code>val</code> escritas en el README y memorizadas por los tres	Diego
☐	Reporte de paridad de vectores dorados y de concordancia del VAD, listos para mostrar	Diego
☐	README final revisado y firmado por los tres	Todos
☐	Respuestas de los jueces (§17) incorporadas y §16 actualizada	Paul
☐	Tres ensayos cronometrados del recorrido de 15 minutos, con reparto de voz entre los tres	Todos
☐	Plan de contingencia §18.3 leído en voz alta por los tres; todos saben reiniciar el servicio	Todos
☐	Batería, cargadores, adaptador de video y respaldo de conectividad verificados	Néstor

EN — CLOSING NOTE

This specification is deliberately stricter than a hackathon requires, because the judging criteria are the criteria of a production engineering team: robustness, depth, feasibility and latency. The two decisions most likely to determine the outcome are not modelling decisions at all — they are the early public deployment at the end of F1, and the 06:00 code freeze. Everything else in this document exists to make those two possible.